# Signaux, Sons et Images pour l'Informaticien: Regression logistique

Diane Lingrand

Polytech SI3

2017 - 2018

# Outline

# Ensemble d'apprentissage : classification par kmean : $k_1 = 50$, $k_2 = 2$. 40 sur 63

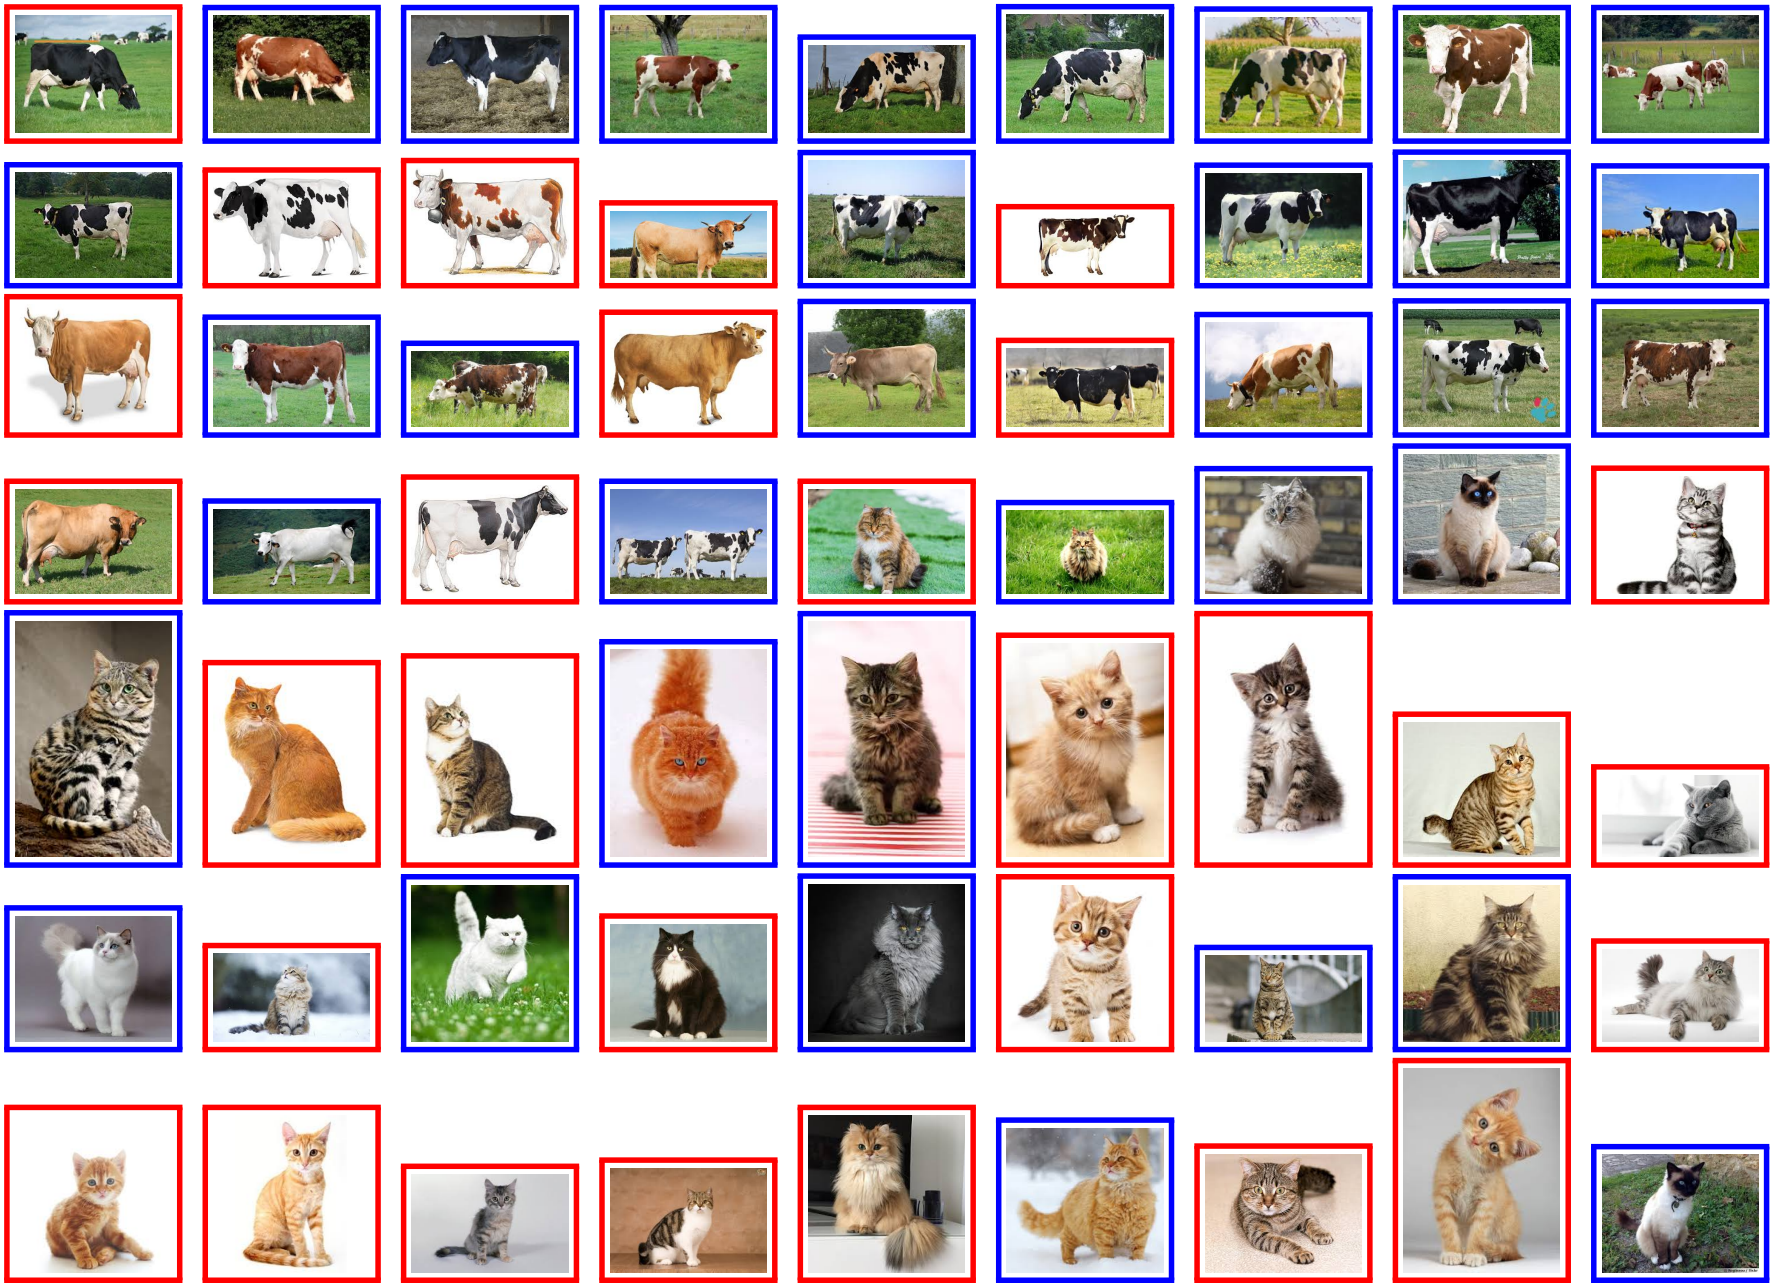

# Ensemble de test : 6 reconnues sur 17

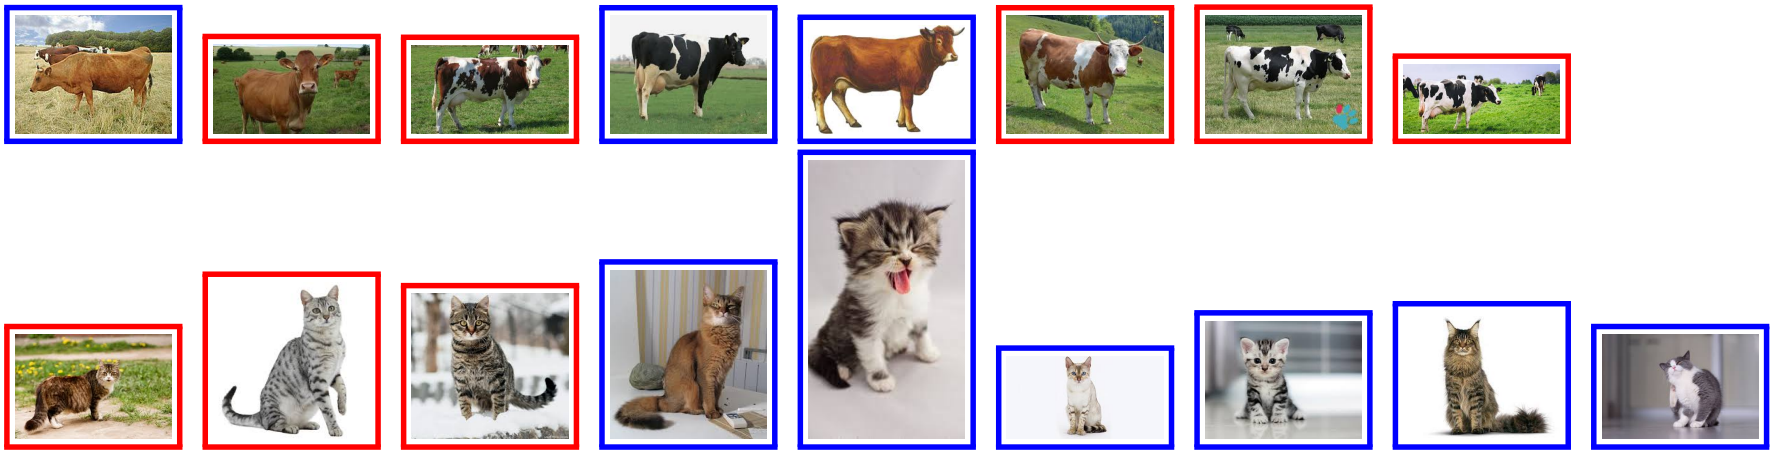

# Classification vaches / chats

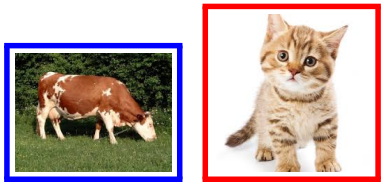

- Echec de la classification par 2 kmeans :
  - ensemble d'apprentissage : 40 / 63 Matrice de confusion :

| | | classes estimées | |
|---|---|---|---|
| | | vache | chat |
| classes réelles | vache | 21 | 10 |
| | chat | 13 | 19 |

  - ensemble de test : 6 / 17 Matrice de confusion :

| | | classes estimées | |
|---|---|---|---|
| | | vache | chat |
| classes réelles | vache | 3 | 5 |
| | chat | 6 | 3 |

# Retour sur le *kmean* : points dans le plan

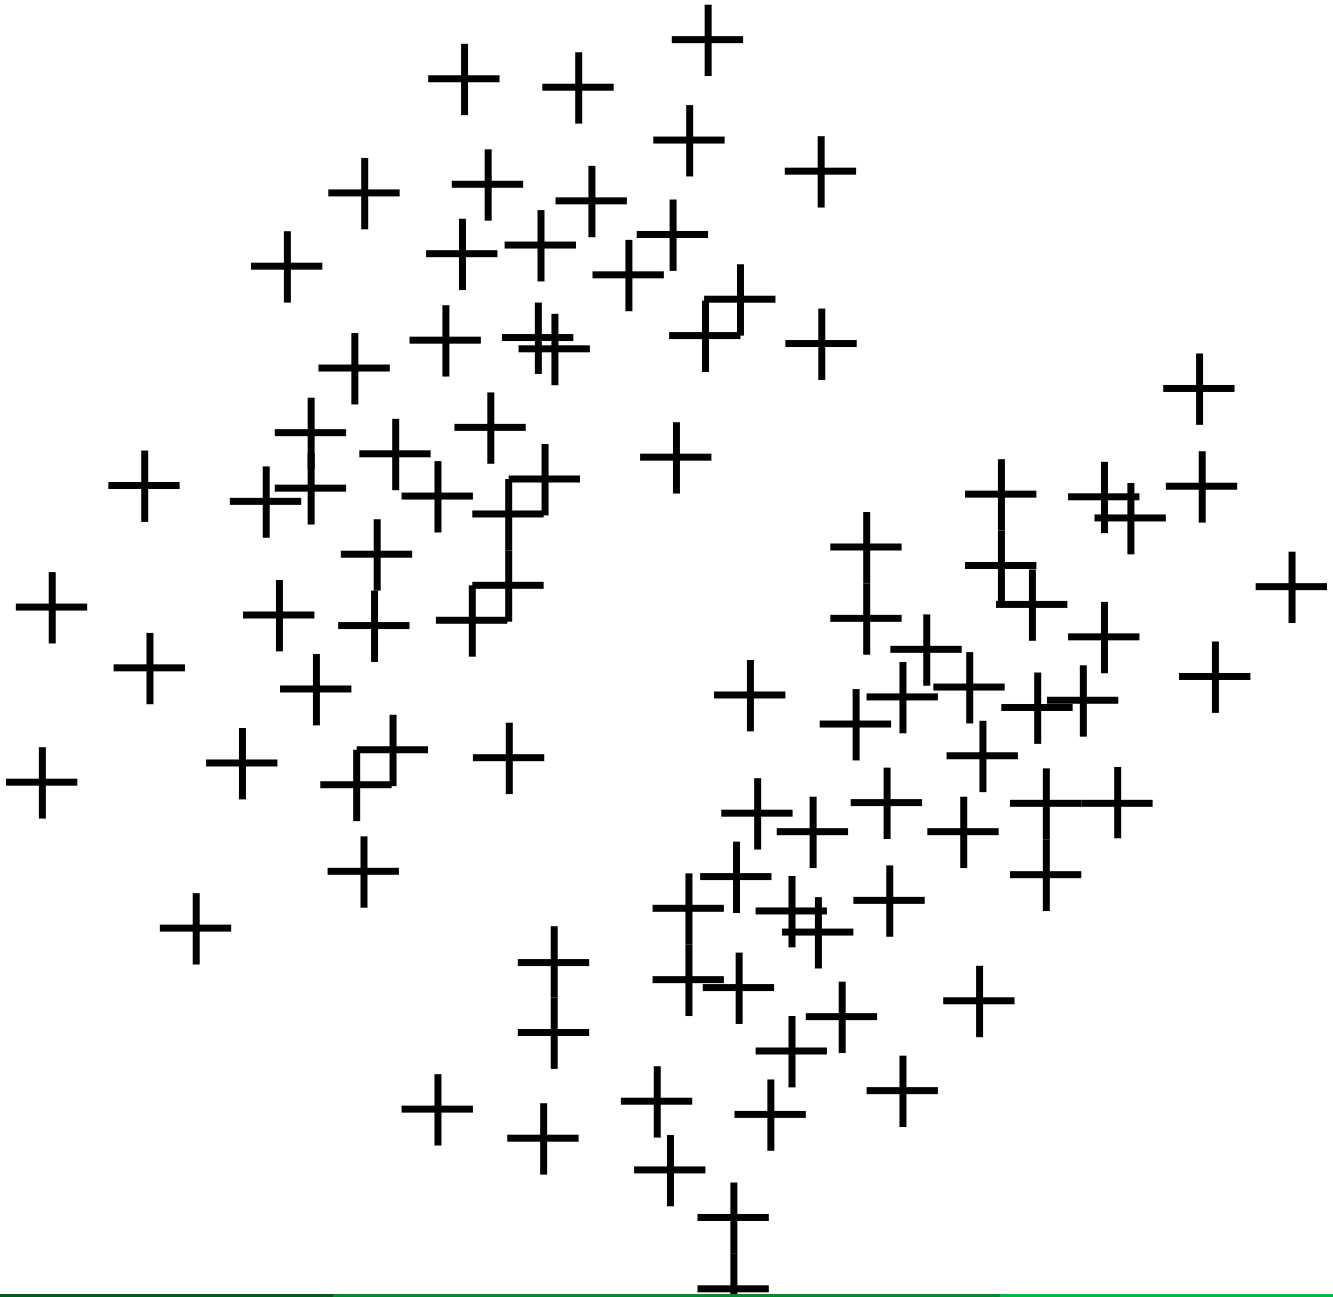

# Séparation en deux ensembles par *kmean*

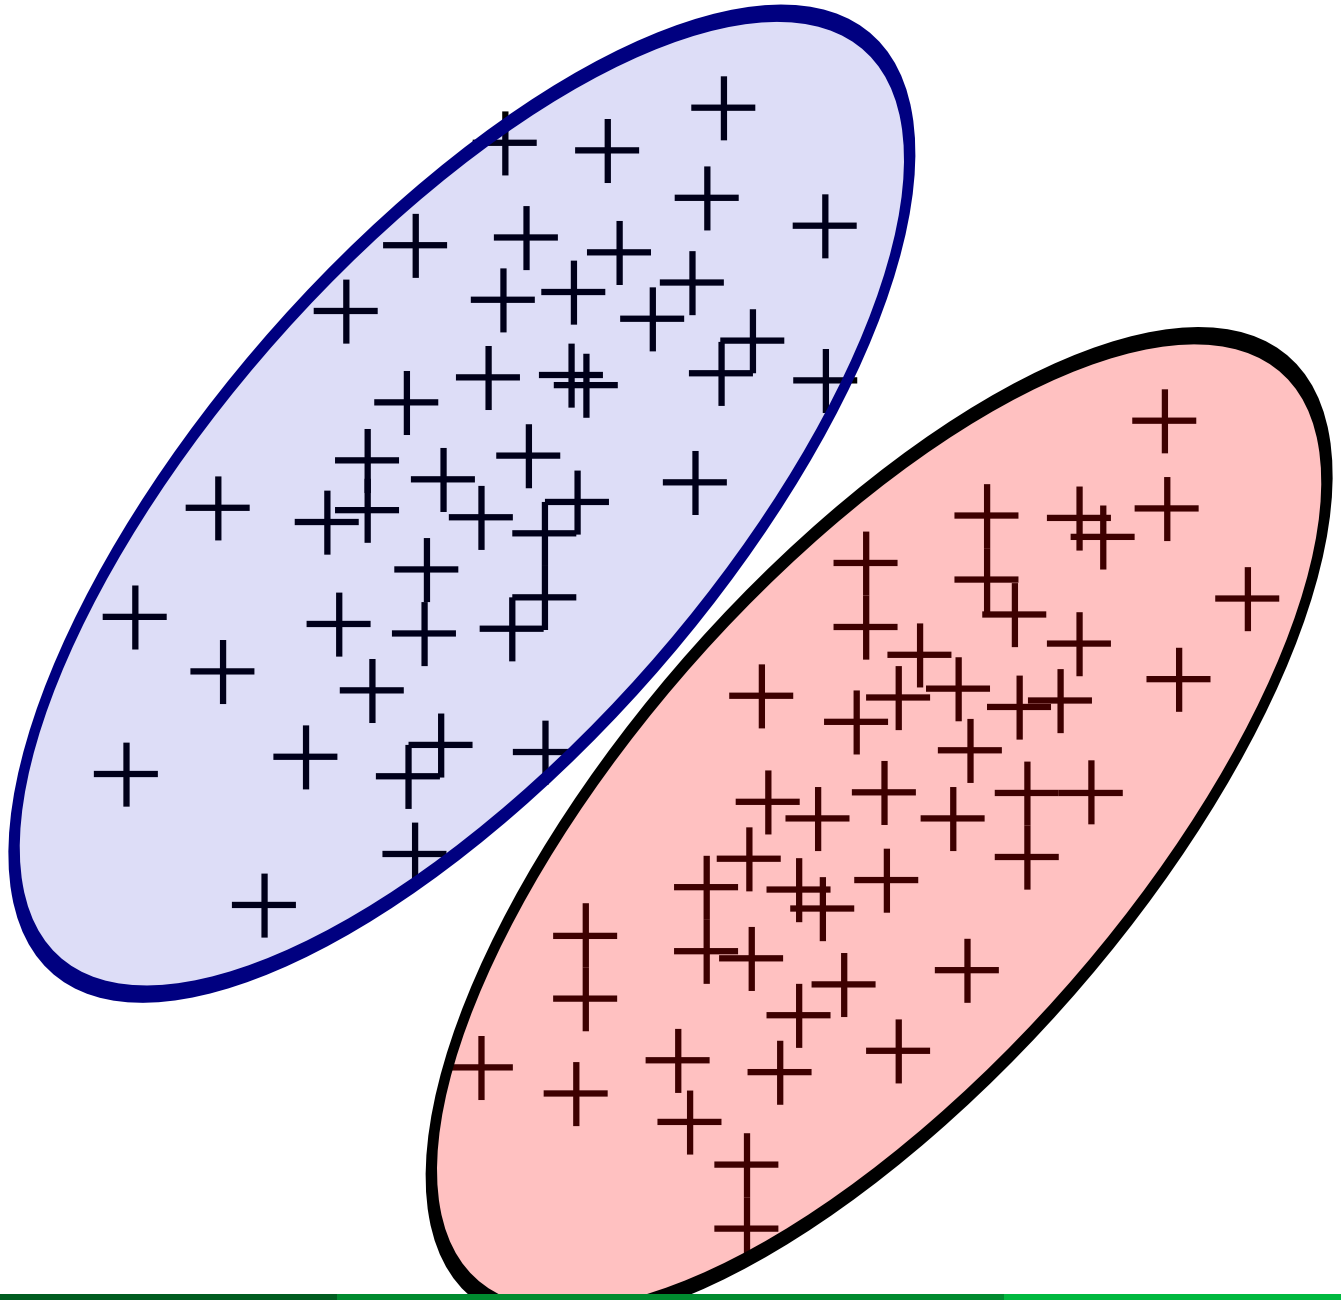

# Utilisation des classes des points : régression logistique

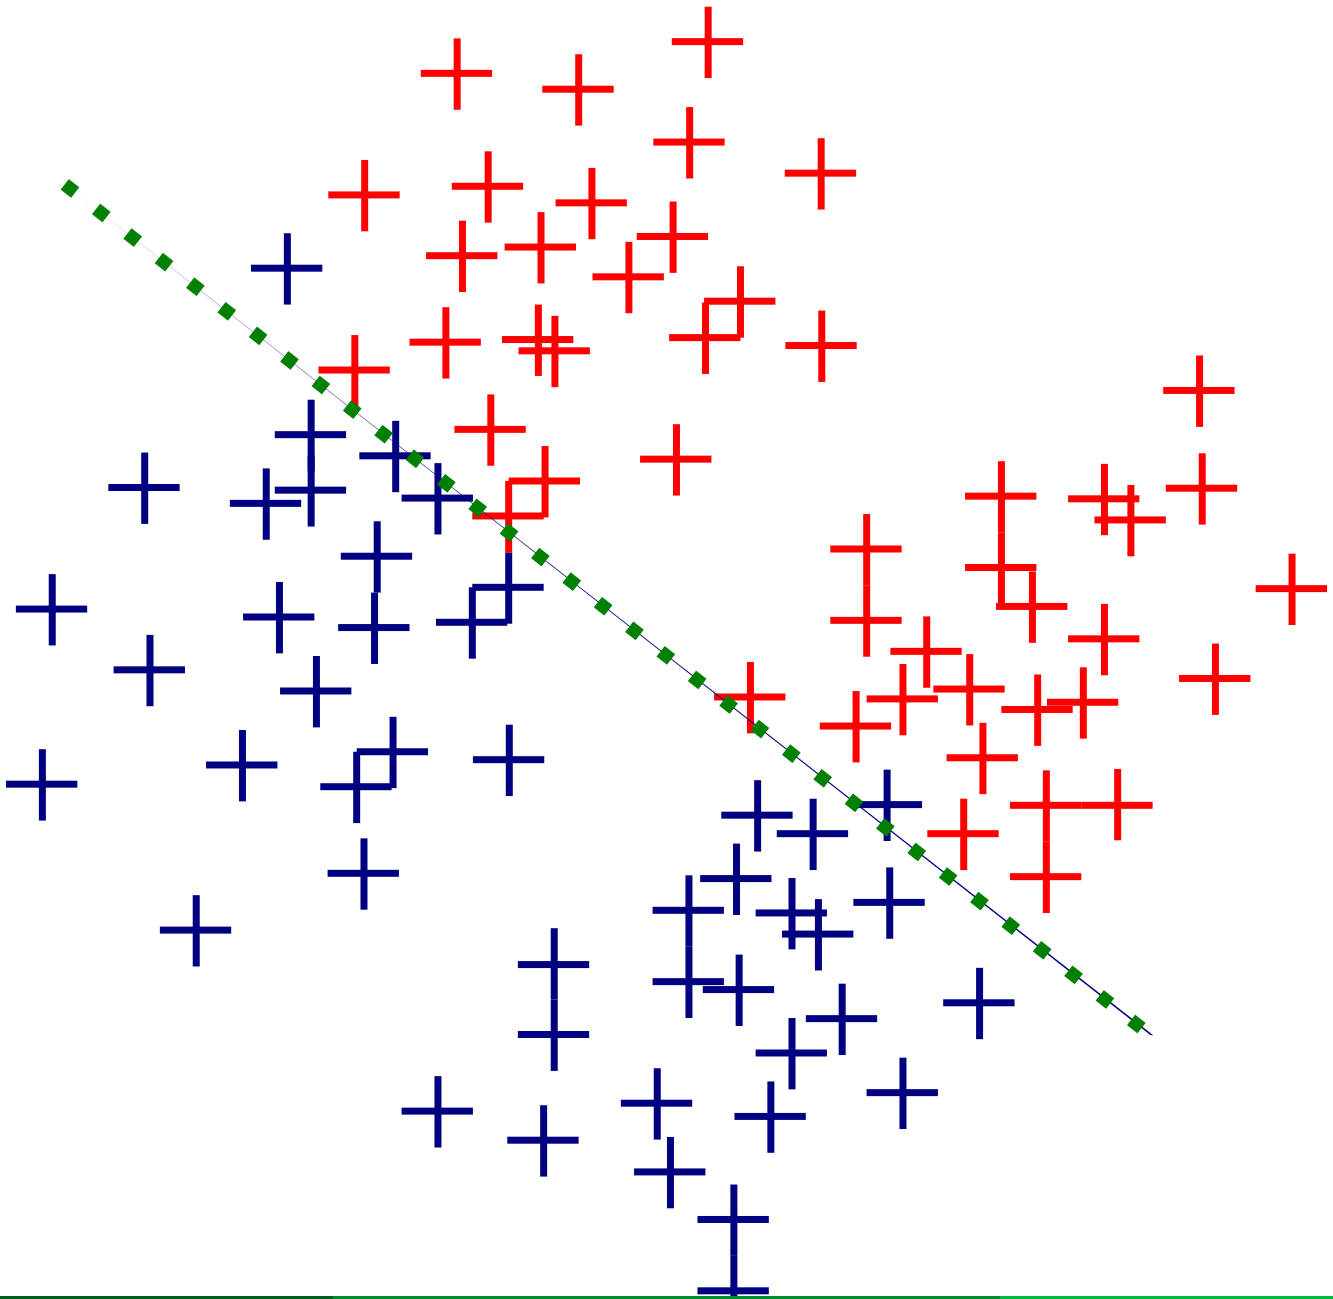

# Outline

# Contexte : apprentissage supervisé

- Apprentissage supervisé : on apprend à partir de données et de leurs classes
- Apprentissage non supervisé : on apprend une représentation des données

Pour l'ensemble d'apprentissage, on connait la solution : il faut l'utiliser !

# Régression logistique (*logistic regression*)

- Séparation de données selon leurs labels (0 ou 1).
  - Séparation linéaire : droite ou hyperplan
  - Séparation non-linéaire : polynomiale ou gaussienne
- Notations :
  - données : $\mathbf{x} = [x_1\ x_2 ...]$
  - labels : $y \in \{0, 1\}$
  - critère de décision $h_\theta$ de paramètre $\theta$
    - $\theta = [\theta_0\ \theta_1\ ...]$

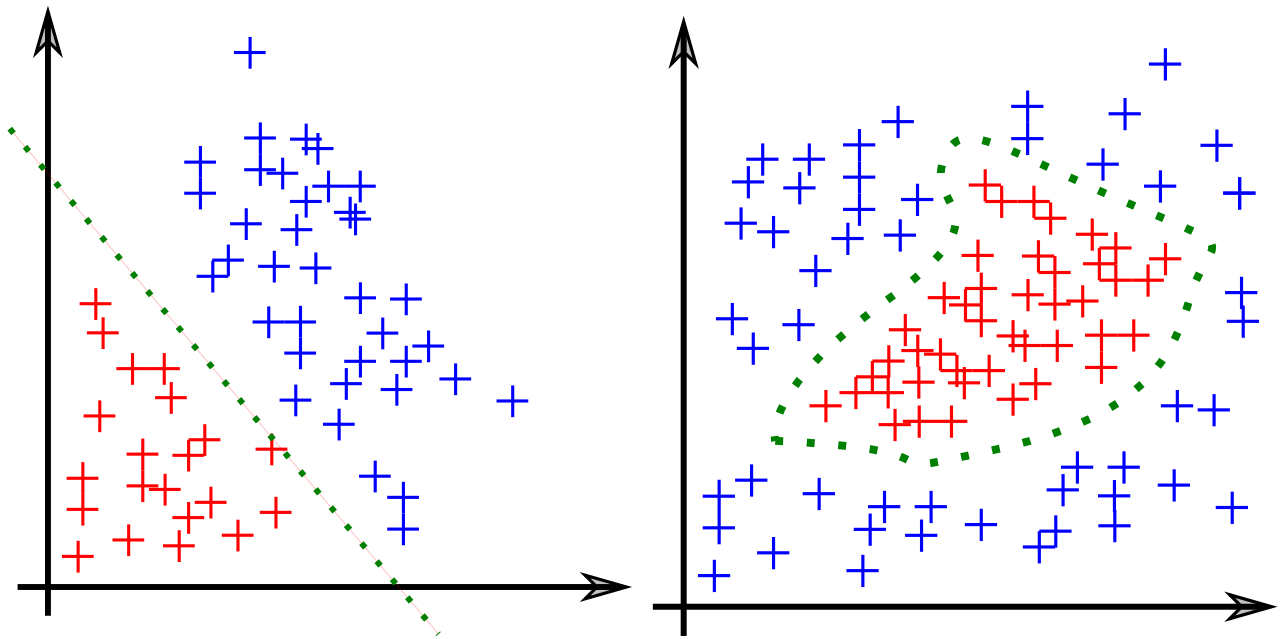

# Séparation linéaire

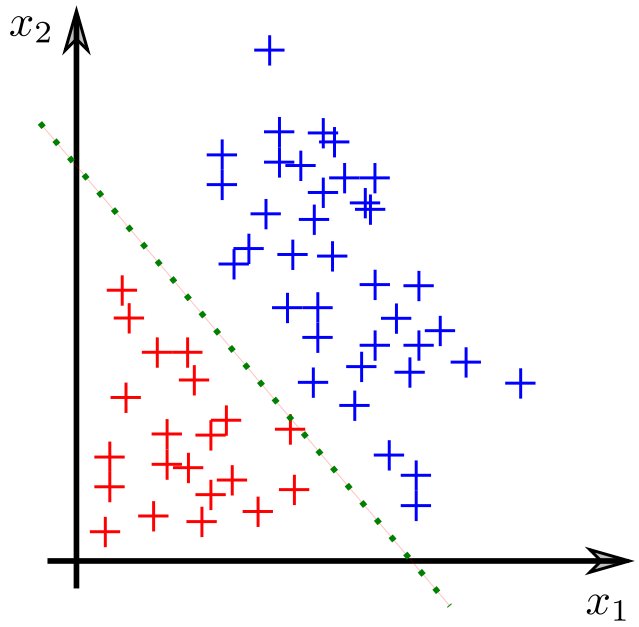


- Frontière de décision :
  - droite d'équation $\theta_0 + \theta_1 x_1 + \theta_2 x_2$
  - s'écrit aussi : $\theta^T \mathbf{x} = 0$
- Décision :
  - si $\theta^T \mathbf{x} \geq 0$ alors $y = 1$
  - si $\theta^T \mathbf{x} < 0$ alors $y = 0$

# Function logistique

$$h_\theta(\mathbf{x}) = s(\theta^T \mathbf{x})$$

avec :

$$s(z) = \frac{1}{1 + e^{-z}}$$

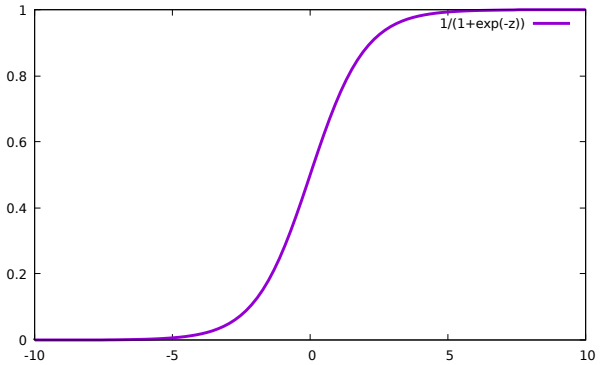


- La décision devient :
  - si $h_\theta(\mathbf{x}) \geq 0.5$ alors $y = 1$
  - si $h_\theta(\mathbf{x}) < 0.5$ alors $y = 0$

# Régression logistique : apprentissage

- données d'apprentissage : $(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), ..., (\mathbf{x}^{(m)}, y^{(m)})$
- $m$ données d'apprentissage
- but de l'apprentissage : trouver $\theta$
- méthode :
  - minimisation d'une erreur
  - descente de gradient (ou autre méthode de minimisation)

# Fonction de coût

$$J = -\frac{1}{m}\sum_{i=1}^{m}(y^{(i)}\log(h_\theta(\mathbf{x^{(i)}})) + (1-y^{(i)})\log(1-h_\theta(\mathbf{x^{(i)}})))$$

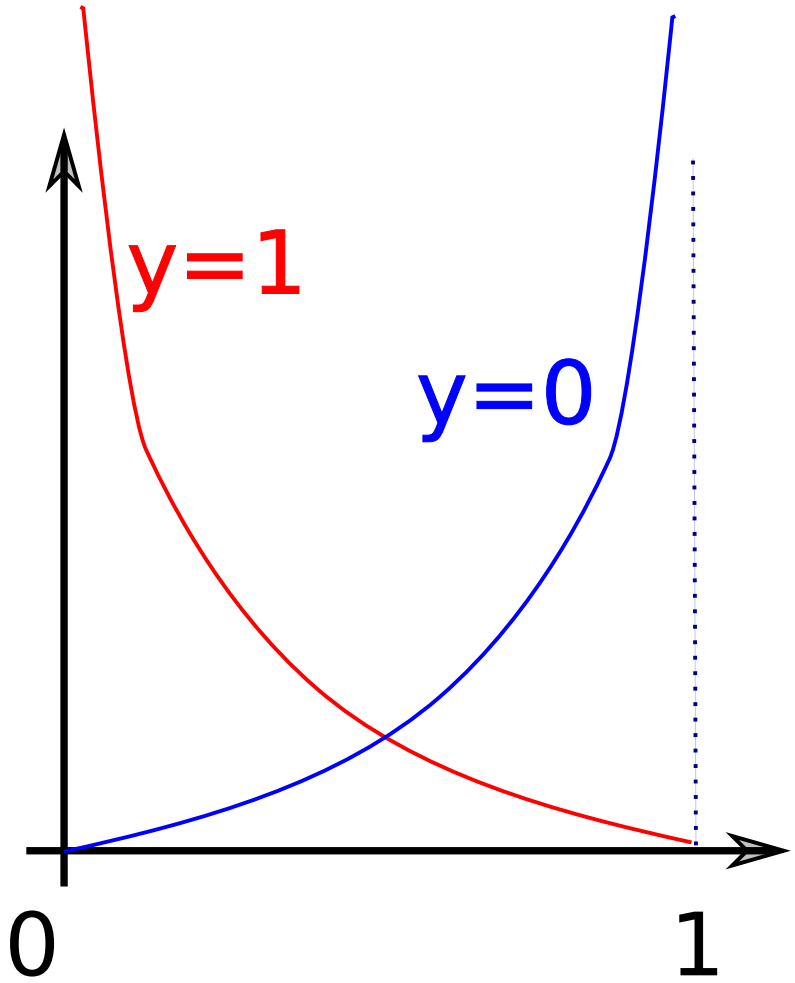

# Descente de gradient

Pour toutes les composantes $\theta_j$ de $\theta$ :

$$\theta_j = \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

avec

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} (h_\theta(\mathbf{x^{(i)}}) - y^{(i)}) x_j^{(i)}$$

# Outline

# Ensemble d'apprentissage, $k_1 = 50$ : score = 100%

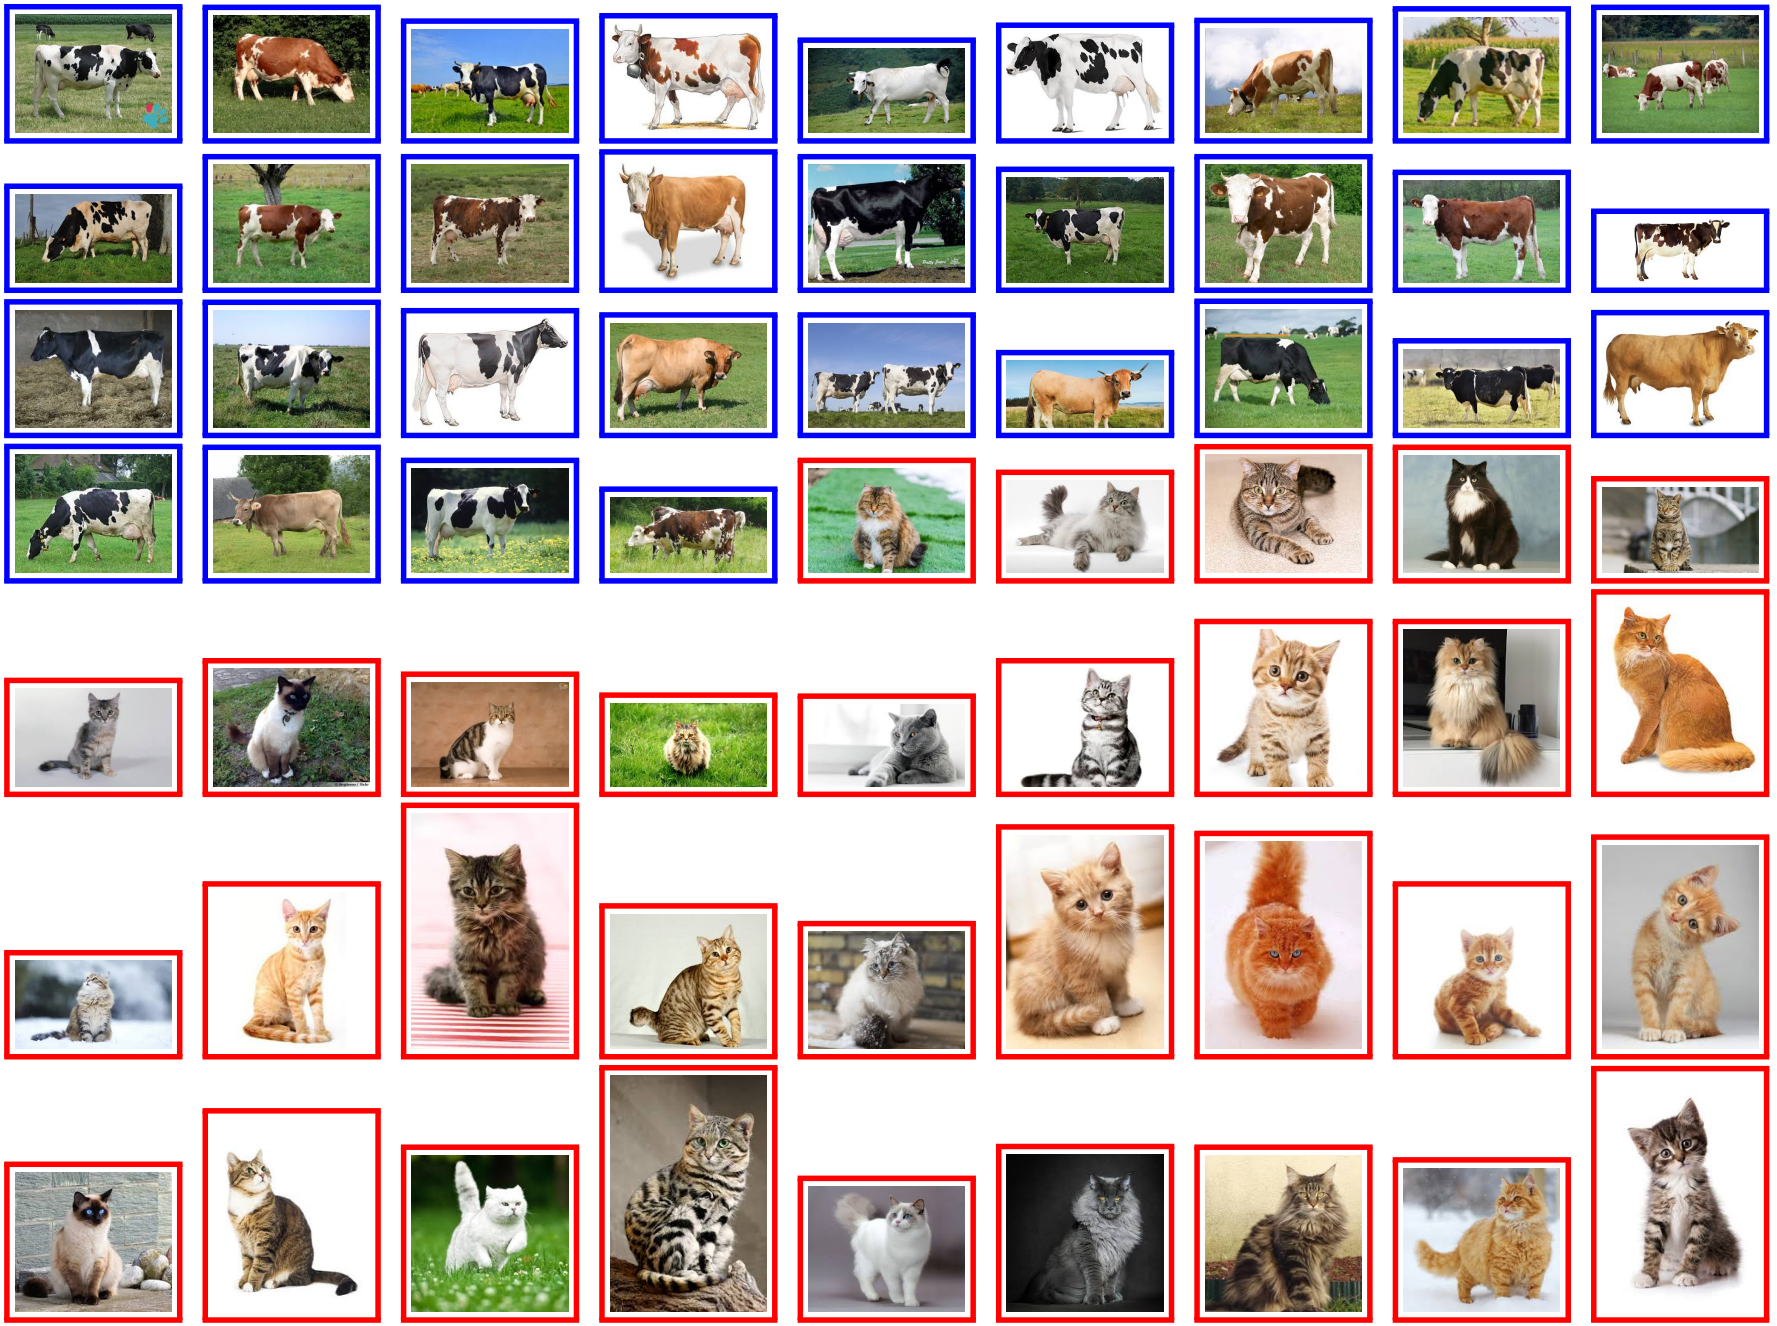

# Ensemble de test : score 94%

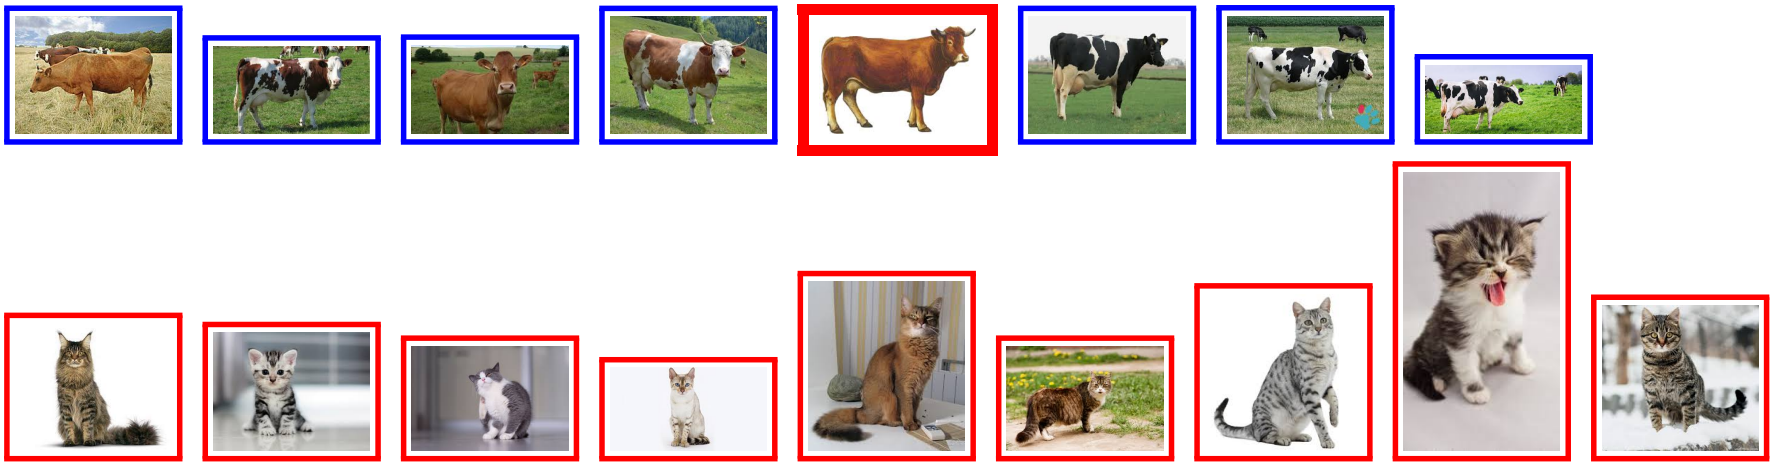

Matrice de confusion :

| | | classes estimées | |
|---|---|---|---|
| | | vache | chat |
| classes réelles | vache | 7 | 1 |
| | chat | 0 | 8 |

# *Logistic regression* en TP

Pour la base d'apprentissage :

- représentation de chaque image par un *bow*
- liste de tous les *bow* et de tous les labels
  - correspondances entre *bow* et label (0 ou 1)
- calcul du score sur la base d'apprentissage
- sauvegarde des paramètres du *kmean* et de la régression logistique

Pour la base de test :

- chargement des paramètres appris pour le *kmean* et la régression logistique
- calcul des bows pour chaque image
- prédiction des labels de chaque image et comparaison avec les vrais labels (calcul de score)

# *Logistic regression* en python

```
#création d'un objet de regression logistique
logisticRegr = LogisticRegression()
#apprentissage
logisticRegr.fit(bows, labels)
#calcul des labels prédits
labelsPredicted = logisticRegr.predict(bows)
#calcul et affichage du score
score = logisticRegr.score(bows, groundTruth)
print("train score = ", score)
#sauvegarde de l'objet
with open('sauvegarde.logr', 'wb') as output:
    pickle.dump(logisticRegr, output, pickle.HIGHEST_PROTOCOL)
#chargement de l'objet
with open('sauvegarde.logr',  'rb') as input:
    logisticRegr = pickle.load(input)
```

# Une approche classique